

Efeito da Normalização Diagonal na U-Matrix de Mapas Auto-Organizáveis Retangulares: Análise Multidataset e Multi-Semente com Correção de Multiplicidade

Cauã Vitor

Resumo—A Matriz de Distâncias Unificada (*U-matrix*) é a principal ferramenta de visualização e segmentação de Mapas Auto-Organizáveis (SOM) com grade retangular. A formulação clássica de Costa & Netto (2007), que generaliza Ultsch (1993), exige a divisão das distâncias diagonais pelo fator geométrico $\sqrt{2}$ para garantir a isotropia do gradiente espacial no espaço de pesos. Este artigo demonstra, mediante análise do código-fonte e estudo experimental de larga escala—1 080 treinamentos SOM abrangendo $N = 30$ sementes aleatórias, 6 dimensões de mapa, 2 topologias e 3 datasets benchmark (*Synthetic Control*, *Wine* e *Digits*)—que a biblioteca open-source IntraSOM (versão 1.1.1) não aplica esse fator de normalização. A divergência resultante é sistemática: a implementação atual inflaciona a U-matrix em 16,8%–20,5% (razão de escala média 1,168–1,205), com alta correlação espacial de Pearson ($r \geq 0,922$ em geral, $r \geq 0,988$ em média) entre as duas versões. A derivação teórica estabelece $(1 + \sqrt{2})/2 \approx 1,207$ como limite assintótico superior. O impacto sobre a segmentação de clusters foi avaliado por testes de Wilcoxon emparelhados com correção de Benjamini-Hochberg ($FDR q = 0,05$): a hipótese nula H_0 foi rejeitada em 55,6% das configurações testadas (20 de 36 testes: 75% em *Synthetic Control*, 67% em *Wine*, 25% em *Digits*), com tamanho de efeito de médio a elevado (r_{effect} de Rosenthal entre 0,39 e 1,00). Isso demonstra que a normalização diagonal causa um impacto estatisticamente significativo e real sobre a segmentação *downstream* na maioria das configurações, diminuindo sua detectabilidade conforme aumenta a sobreposição de classes no dataset. Este trabalho contribui com: (i) derivação analítica do fator de inflação 2-D e generalização teórica 3-D; (ii) estudo multidataset com $N = 30$ sementes e tamanhos de efeito; (iii) protocolo de conformidade executável (`src/conformance_check.py`) para bibliotecas SOM; e (iv) proposta concreta de correção via API.

Index Terms—Mapas Auto-Organizáveis, U-Matrix, Normalização Diagonal, IntraSOM, Wilcoxon, FDR, Tamanho de Efeito, Reprodutibilidade, Conformidade de Software.

1 INTRODUÇÃO

C. Vitor é graduando em Engenharia Elétrica e pesquisador na Universidade Federal do Rio Grande do Norte (UFRN), Natal, RN, Brasil. E-mail: caua.vitor.016@ufrn.edu.br.
Supervisão Acadêmica: Prof. Dr. José Alfredo Ferreira Costa (Departamento de Engenharia Elétrica, UFRN). O orientador forneceu supervisão acadêmica e discussão conceitual sobre a U-matrix, sem envolvimento direto na execução dos experimentos numéricos ou na redação deste manuscrito.

OS Mapas Auto-Organizáveis de Kohonen (*Self-Organizing Maps* — SOM) [1], [2] são amplamente utilizados para projeção e visualização de dados multidimensionais em grades de baixa dimensão, com aplicações em agrupamento, detecção de anomalias e exploração de dados de alta dimensão [3], [4]. A biblioteca IntraSOM [5], publicada no periódico *Software Impacts*, destaca-se como um pacote open-source em Python desenvolvido para malhas hexagonais e toroidais com suporte a dados ausentes, sendo adotada em pesquisas aplicadas em centros como o InTRA-USP.

Com o aumento da adoção de bibliotecas de aprendizado de máquina em sistemas numéricos, a verificação formal de fidelidade algorítmica torna-se essencial [6], [7]. A ausência de testes de conformidade (*conformance testing*) entre a fórmula publicada e a rotina numérica executada representa uma fonte de dívida técnica em sistemas de IA [8], [9]. Conforme apontado por Flexer (2001) [10], a ausência de padronização na U-matrix pode comprometer a comparabilidade entre estudos que utilizam ferramentas distintas.

Uma das representações mais influentes para a interpretação de mapas treinados é a Matriz de Distâncias Unificada (*U-matrix*), introduzida por Ultsch & Siemon (1990) [11], detalhada por Ultsch (1993) [12] e formalizada matematicamente por Costa & Netto (2007) [13]. A U-matrix converte distâncias no espaço de pesos em relevos tridimensionais onde vales identificam regiões homogêneas e cristas marcam fronteiras entre classes, sendo amplamente empregada em análise exploratória de dados de alta dimensão [4], [14].

Este trabalho documenta e quantifica uma divergência concreta na versão 1.1.1 da biblioteca IntraSOM: a implementação da U-matrix reduzida para grades retangulares não aplica o fator de normalização espacial $1/\sqrt{2}$ nas conexões diagonais previsto por Costa & Netto (2007) [13]. Mediante um estudo empírico de larga escala—1 080 modelos SOM, $N = 30$ sementes, 3 datasets, 6 dimensões de mapa—demonstra-se que essa omissão produz inflação sistemática e mensurável, com impacto estatisticamente significativo sobre a segmentação.

As contribuições deste artigo são:

- 1) **Derivação Analítica 2-D e 3-D:** Demonstração do fator de inflação teórico $(1 + \sqrt{2})/2 \approx 1,207$ (2-D) e generalização para U-arrays 3-D $((6 + 12\sqrt{2} + 8\sqrt{3})/26 \approx 1,416)$.
- 2) **Estudo Multidataset e Multissemente:** $N = 30$ sementes em 3 datasets benchmark, com intervalos de confiança bootstrap de 95% (1 000 reamostras), testes de Wilcoxon emparelhados com correção FDR de Benjamini-Hochberg [15] e análise de tamanho de efeito (r_{effect} de Rosenthal).
- 3) **Generalização Cruzada:** Validação dos achados em datasets com estruturas distintas (*Synthetic Control*, *Wine*, *Digits*), demonstrando como a sobreposição de classes modera a detectabilidade do efeito.
- 4) **Framework de Conformidade Executável:** Proposta e disponibilização de protocolo de testes de conformidade (`src/conformance_check.py`).
- 5) **Proposta de Correção:** Extensão da API via parâmetro `normalize_diagonals`.

2 TRABALHOS RELACIONADOS

2.1 U-Matrix e Visualização de SOMs

A U-matrix foi introduzida por Ultsch & Siemon (1990) [11] e formalizada por Ultsch (1993) [12] para grades retangulares e hexagonais. Costa & Netto (2007) [13] generalizaram a formulação para mapas tridimensionais (U-array), estabelecendo explicitamente o fator $1/\sqrt{2}$ para normalização diagonal na grade retangular—a referência principal deste trabalho. Vesanto & Alhoniemi (2000) [4] analisaram diferentes métodos de agrupamento baseados em SOMs, incluindo variantes da U-matrix, e demonstraram que a escolha do esquema de distância afeta diretamente a qualidade da segmentação. Venna & Kaski (2007) [14] estenderam o uso da U-matrix para visualização de dados genômicos de alta dimensão, destacando a sensibilidade da representação ao esquema de normalização adotado. Flexer (2001) [10] discutiu sistematicamente as implicações da falta de padronização na U-matrix entre bibliotecas distintas, antecipando o problema investigado neste artigo.

2.2 Reprodutibilidade e Dévida Técnica em Software Científico

Sculley et al. (2015) [8] catalogaram padrões de dévida técnica em sistemas de ML, incluindo dependências não documentadas de implementação que comprometem a reprodutibilidade. Stodden & Miguez (2014) [7] e Peng (2011) [6] estabeleceram melhores práticas para reprodução computacional, enfatizando a necessidade de documentação explícita de escolhas de implementação. Sandve et al. (2013) [9] propuseram dez regras para pesquisa computacional reproduzível, incluindo a gravação das versões exatas de software utilizadas. A divergência entre código e equação publicada encontrada na IntraSOM v1.1.1 representa um caso concreto desse fenômeno.

2.3 Bibliotecas SOM e Variantes de Implementação

O pacote `kohonen` em R [16] também adota a média simples de normas brutas sem normalização diagonal—variante distinta da formulação de Costa & Netto (2007). Esse padrão de variação silenciosa entre bibliotecas é sistematicamente apontado por Flexer (2001) [10] como fonte de incomparabilidade entre estudos. Ao contrário dos trabalhos anteriores, que documentam a variabilidade *entre* implementações, este artigo é o primeiro, ao nosso conhecimento, a quantificar formalmente a divergência *interna* da IntraSOM v1.1.1 em relação à sua própria referência teórica [13], mediante um protocolo estatisticamente rigoroso de $N = 30$ sementes, tamanhos de efeito e correção de multiplicidade FDR.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 O Algoritmo SOM e o Espaço de Pesos

O SOM de Kohonen [1] consiste em $M = R \times C$ neurônios dispostos em grade retangular de R linhas e C colunas. A cada neurônio (r, c) está associado um vetor de pesos $\mathbf{w}_{r,c} \in \mathbb{R}^n$. Dados de entrada $\mathbf{x} \in \mathbb{R}^n$ são mapeados para o Neurônio de Melhor Ajuste (*Best Matching Unit* — BMU):

$$(r^*, c^*) = \arg \min_{r,c} \{\|\mathbf{x} - \mathbf{w}_{r,c}\|\}. \quad (1)$$

Os vetores de pesos são atualizados iterativamente segundo a regra de Kohonen [3], com função de vizinhança gaussiana de raio $\sigma(t)$ decrescente ao longo das épocas.

3.2 Formulação Clássica da U-Matrix

A U-matrix codifica a estrutura de densidade do espaço de pesos [12]. Para uma grade retangular, Costa & Netto (2007) [13] definem as distâncias inter-neurônios nas direções ortogonais e diagonais:

$$dx(r, c) = \|\mathbf{w}_{r,c} - \mathbf{w}_{r,c+1}\|, \quad (2)$$

$$dy(r, c) = \|\mathbf{w}_{r,c} - \mathbf{w}_{r+1,c}\|, \quad (3)$$

$$dxy(r, c) = \frac{\|\mathbf{w}_{r,c} - \mathbf{w}_{r+1,c+1}\| + \|\mathbf{w}_{r,c+1} - \mathbf{w}_{r+1,c}\|}{2\sqrt{2}}. \quad (4)$$

O elemento crítico da Eq. (4) é o divisor $2\sqrt{2}$. Em uma grade retangular com passo unitário, a distância geométrica entre neurônios diagonalmente adjacentes é $\sqrt{2}$. Dividir por $\sqrt{2}$ normaliza o gradiente espacial $\Delta \mathbf{w} / \Delta s$ pelo comprimento do passo diagonal $\Delta s = \sqrt{2}$. Sem essa normalização, os canais diagonais recebem implicitamente um peso $\sqrt{2} \approx 1,414$ vezes maior que os ortogonais na média final, distorcendo a isotropia da U-matrix.

A U-matrix reduzida por neurônio é a média das distâncias normalizadas de todos os vizinhos válidos [4], [10]:

$$U(r, c) = \frac{1}{|\mathcal{N}(r, c)|} \sum_{k \in \mathcal{N}(r, c)} d_k(r, c) / s_k, \quad (5)$$

em que $s_k = 1$ para vizinhos ortogonais e $s_k = \sqrt{2}$ para vizinhos diagonais, e $\mathcal{N}(r, c)$ é o conjunto de vizinhos válidos de (r, c) .

4 ANÁLISE DA DIVERGÊNCIA NA BIBLIOTECA INTRASOM

4.1 Implementação Observada

A inspeção do método `build_umatrix` na classe `SOM` da biblioteca `IntraSOM` (linha 2626 de `intrasom/intrasom.py`, versão 1.1.1) [5] revela que, para a grade retangular (`lattice == "rect"`), todos os oito vizinhos recebem norma euclidiana bruta dos pesos sem o fator $1/\sqrt{2}$ nas direções diagonais:

```
offsets = np.array([
    [1,0], [1,1], [0,1], [-1,1],
    [-1,0], [-1,-1], [0,-1], [1,-1]
], dtype=int)
for k in range(8):
    um[:, :, k] = np.linalg.norm(
        W - W_neighbor, axis=2)
umat = np.nanmean(um, axis=2)
```

A implementação conforme a Eq. (5) requer a divisão por $\sqrt{2}$ nos quatro canais diagonais ($k \in \{1, 3, 5, 7\}$) antes de calcular `np.nanmean`.

4.2 Derivação do Limite Teórico de Inflação 2-D

Considere um mapa com pesos perfeitamente regulares, onde as distâncias ortogonais $d_{\perp}$ e diagonais $d_{\diag}$ satisfazem $d_{\diag} = \sqrt{2} d_{\perp}$ (gradiente isotrópico). Então:

$$U_{\text{IntraSOM}} = \frac{4d_{\perp} + 4d_{\diag}}{8} = \frac{4d_{\perp}(1 + \sqrt{2})}{8},$$

$$U_{\text{class.}} = \frac{4d_{\perp} + 4d_{\diag}/\sqrt{2}}{8} = d_{\perp},$$

$$\text{Razão} = \frac{U_{\text{IntraSOM}}}{U_{\text{class.}}} = \frac{1 + \sqrt{2}}{2} \approx 1,207.$$

O valor 1,207 (20,7% de inflação) representa o **limite assintótico superior** sob isotropia perfeita em 2-D.

4.3 Extensão Teórica a Saídas 3-D: U-Array

Costa & Netto (2007) [13] estenderam a U-matrix para grades tridimensionais (*U-array*), onde um neurônio interno possui 26 vizinhos no cubo $3 \times 3 \times 3$: 6 ortogonais ($s = 1$), 12 diagonais de face ($s = \sqrt{2}$) e 8 diagonais de canto/corpo ($s = \sqrt{3}$).

Sob um gradiente de pesos 3-D perfeitamente isotrópico, o U-array sem normalização espacial resulta em:

$$U_{\text{unnorm}}^{3D} = \frac{6(1) + 12(\sqrt{2}) + 8(\sqrt{3})}{26} d_{\perp} \approx 1,4164 d_{\perp}. \quad (6)$$

Enquanto a formulação clássica normalizada por s_k produz $U_{\text{class}}^{3D} = d_{\perp}$. Dessa forma, a omissão da normalização diagonal em um U-array 3-D gera uma **inflação assintótica teórica** de 41,64% (razão 1,4164).

Inspeção do código-fonte da `IntraSOM` (v1.1.1) confirma que a biblioteca suporta estritamente grades bidimensionais (`self.lattice` exige "rect" ou "hexa"). Assim, a estrutura 3-D permanece como uma extensão teórica preditiva deste artigo, cuja validação empírica é declarada como Trabalho Futuro.

5 METODOLOGIA EXPERIMENTAL

5.1 Datasets Benchmark

O estudo utiliza três datasets de referência selecionados para cobrir níveis crescentes de sobreposição entre classes (baixa, média e alta), permitindo avaliar a moderação da sobreposição sobre a detectabilidade do efeito:

- **Synthetic Control** [17]: 600 séries temporais de 60 atributos, 6 classes morfológicas ($n = 100$ por classe). Dataset de baixa sobreposição e separação morfológica clara.
- **Wine** (Forina et al., UCI): 178 amostras, 13 atributos químicos, 3 cultivares. Dataset de média dificuldade, com sobreposição parcial entre classes.
- **Digits** (Kaynak & Alpaydin, scikit-learn): 1797 amostras, 64 atributos (imagens 8×8), 10 classes de dígitos manuscritos. Dataset de alta dimensão com sobreposição elevada.

5.2 Protocolo Experimental

Para cada combinação dataset $\times$ tamanho de mapa $\times$ topologia, treinaram-se SOMs retangulares com:

- **Dimensões:** 5×5 , 7×7 , 10×10 , 12×12 , 15×15 , 20×20 .
- **Topologias:** Planar e Toroidal.
- **Sementes:** $N = 30$ (sementes 42...71), com inicialização aleatória estocástica (`initialization='random'`).
- **Treinamento:** Batch SOM, 150 épocas rugosas + 350 finas.

O total de modelos treinados foi $3 \times 6 \times 2 \times 30 = 1080$. Todos os códigos, dados e sementes são disponibilizados no repositório público do projeto [7], [9].

5.3 Métricas e Testes Estatísticos

Para cada modelo, computam-se a U-matrix `IntraSOM` (U_A) e a U-matrix Clássica (U_B , com normalização diagonal $1/\sqrt{2}$). As seguintes métricas são calculadas e reportadas como média $\pm$ desvio padrão com intervalos de confiança bootstrap de 95% (1000 reamostras, método percentil [18]) sobre as 30 sementes:

- **Pearson r :** correlação espacial entre U_A e U_B .
- **Diferença Relativa (%):** $|U_A - U_B|/U_B \times 100$.
- **Razão de Escala:** U_A/U_B .
- **ARI de Segmentação:** Adjusted Rand Index entre as partições de k clusters (K-Means sobre U_A e U_B).
- **ARI Downstream:** ARI entre a segmentação da U-matrix e os rótulos reais do dataset: $\text{ARI}(y, \text{seg}_A)$ e $\text{ARI}(y, \text{seg}_B)$.
- **Tamanho de Efeito:** $r_{\text{effect}} = |Z|/\sqrt{N}$ de Rosenthal para o teste de Wilcoxon emparelhado e d_z de Cohen para diferenças emparelhadas.

Para cada configuração (tamanho, topologia), aplica-se o **teste de Wilcoxon emparelhado** [19] comparando $\text{ARI}(y, \text{seg}_A)$ versus $\text{ARI}(y, \text{seg}_B)$ sobre as 30 sementes. Os 12 p -valores por dataset são corrigidos pelo procedimento de **Benjamini-Hochberg** (FDR $q = 0,05$) [15].

5.4 Nota sobre Reprodutibilidade do Protocolo

O pipeline principal de demonstração da aplicação utiliza `initialization='pca'` por recomendação acadêmica para assegurar reprodutibilidade determinística do dashboard visual. Para fins de avaliação estatística de variância, adotou-se exclusivamente `initialization='random'` neste experimento, confirmando variância real nos codebooks ($\max |\mathbf{W}_{42} - \mathbf{W}_{43}| > 2,45$) [7].

6 RESULTADOS

6.1 Visualização Comparativa

A Fig. 1 exibe U_A e U_B para o modelo SOM 10×10 RECT toroidal (seed 42). A topologia relativa é visualmente preservada ($r = 0,9993$), contudo U_A exibe amplitude sistematicamente superior ($\approx 20,5\%$ de inflação média).




Figura 1. Comparação das U-matrizes U_A (IntraSOM v1.1.1) e U_B (Costa & Netto 2007) para SOM 10×10 RECT toroidal: (a) U_A sem normalização; (b) U_B com $1/\sqrt{2}$; (c) $|U_A - U_B|$.

6.2 Dataset *Synthetic Control*: Estatística Multissemente

A Tabela 1 apresenta os resultados sobre o *Synthetic Control* ($N = 30$ sementes), reportando médias de ARI, p_{fdr} do teste de Wilcoxon emparelhado e o tamanho de efeito de Rosenthal (r_{effect}).

A razão de escala varia de 1,168 (mapas planares pequenos) a 1,205 (mapas toroidais grandes), convergindo ao teto teórico 1,207 conforme o mapa cresce. A correlação de Pearson é elevada em todas as configurações ($r \geq 0,990$). Quanto à significância estatística, 9 das 12 configurações (75%) rejeitaram H_0 ($p_{\text{fdr}} < 0,05$), com tamanho de efeito de Rosenthal atingindo $r_{\text{effect}} = 0,862$. Isso confirma que a omissão da normalização diagonal produz uma alteração estatisticamente detectável e quantitativamente expressiva na segmentação de clusters contra o *ground truth*.

6.3 Sistemática e Convergência ao Teto Teórico

A Fig. 2 confirma que a razão de escala média em malhas toroidais ($1,204 \pm 0,001$) se aproxima consistentemente do limite assintótico teórico 1,207. Mapas planares exibem valores ligeiramente inferiores (1,168–1,197) devido à menor densidade de vizinhos diagonais nas bordas abertas.

6.4 Generalização: Datasets *Wine* e *Digits*

A Tabela 2 reporta a correlação de Pearson, a fração de configurações com $p_{\text{fdr}} < 0,05$ e a amplitude do tamanho de efeito nos três datasets.




Figura 2. Sistemática da divergência vs. dimensão N : (a) Divergência relativa (%); (b) Razão de escala $\bar{U}_A/\bar{U}_B$ e teto teórico 1,207.

A Fig. 3 ilustra a concordância de segmentação (ARI entre U_A e U_B) em função da dimensão da grade, evidenciando como grades menores (5×5) são mais sensíveis à variação no relevo local da U-matrix.




Figura 3. Adjusted Rand Index (ARI) entre segmentações U_A e U_B por dimensão de grade N .

A correlação de Pearson permanece elevada nos três datasets ($r \geq 0,988$ em média), confirmando a sistematicidade da inflação. Contudo, a taxa de rejeição de H_0 diminui de 75% (*Synthetic Control*) para 67% (*Wine*) e 25% (*Digits*). Esse comportamento relaciona-se com a sobreposição intrínseca entre classes: em datasets com alta sobreposição (*Digits*), a variância dos dados atenua a sensibilidade da partição macro, tornando as alterações finas da U-matrix menos detectáveis nos testes de hipótese.

No dataset *Wine*, a razão de escala média é 1,196, com 8 configurações significativas. O modelo 7×7 toroidal exibiu tamanho de efeito máximo ($r_{\text{effect}} = 1,000$, $p_{\text{fdr}} = 5,18 \times 10^{-7}$), evidenciando que para mapas de média resolução a omissão da normalização altera drasticamente as partições de clusters.

No dataset *Digits*, as 3 configurações significativas ($p_{\text{fdr}} < 0,05$) foram 5×5 Planar ($p = 0,005$, $r_{\text{effect}} = 0,607$), 7×7 Planar ($p = 0,002$, $r_{\text{effect}} = 0,679$) e 20×20 Planar ($p = 0,035$, $r_{\text{effect}} = 0,479$).

7 DISCUSSÃO

7.1 Significância Prática e Limite Teórico

Os experimentos confirmam que a biblioteca IntraSOM (v1.1.1) [5] computa a U-matrix reduzida com norma euclidiana bruta, resultando em inflação sistemática de 16,8%–20,5%. O limite teórico de 20,7% derivado na Seção 4.2 atua

Tabela 1

Métricas de Divergência e Testes de Hipótese — *Synthetic Control*, $N = 30$ sementes. Médias com IC Bootstrap 95%. p_{fdr} : Benjamini-Hochberg ($q = 0,05$). r_{effect} : Rosenthal ($|Z|/\sqrt{N}$). * $p_{\text{fdr}} < 0,05$.

Modelo	Pearson r	Escala $\bar{U}_A/\bar{U}_B$	ARI GT (U_A)	ARI GT (U_B)	p_{fdr}	Efeito r_{effect}
5 × 5 Planar	0.991 [0.990, 0.991]	1.168	0.232	0.209	< 0.001*	0.839 (Elevado)
5 × 5 Toróide	0.990 [0.990, 0.991]	1.202	0.240	0.192	0.030*	0.433 (Médio)
7 × 7 Planar	0.997 [0.996, 0.997]	1.180	0.248	0.245	0.002*	0.607 (Elevado)
7 × 7 Toróide	0.998 [0.998, 0.999]	1.203	0.244	0.213	< 0.001*	0.695 (Elevado)
10 × 10 Planar	0.998 [0.998, 0.998]	1.188	0.202	0.211	0.292	0.213 (Pequeno)
10 × 10 Toróide	0.999 [0.999, 0.999]	1.204	0.163	0.166	0.452	0.149 (Desprezível)
12 × 12 Planar	0.998 [0.998, 0.999]	1.191	0.178	0.186	< 0.001*	0.804 (Elevado)
12 × 12 Toróide	0.999 [0.999, 0.999]	1.204	0.133	0.138	0.031*	0.422 (Médio)
15 × 15 Planar	0.999 [0.999, 0.999]	1.194	0.167	0.174	0.037*	0.402 (Médio)
15 × 15 Toróide	0.999 [0.999, 0.999]	1.203	0.123	0.136	< 0.001*	0.836 (Elevado)
20 × 20 Planar	0.999 [0.999, 0.999]	1.197	0.141	0.150	< 0.001*	0.862 (Elevado)
20 × 20 Toróide	0.999 [0.999, 0.999]	1.204	0.100	0.099	0.952	0.011 (Desprezível)

Tabela 2

Generalização Multidataset: Pearson r médio, fração de rejeições H_0 ($p_{\text{fdr}} < 0,05$, $N = 30$), escala média e tamanho de efeito máximo.

Dataset	Pearson r	Rej. H_0	Escala Média	r_{eff} (max)
Synthetic Control	0.998	9/12 (75%)	1.193	0.862
Wine	0.997	8/12 (67%)	1.196	1.000 [†]
Digits	0.988	3/12 (25%)	1.193	0.679

[†] No modelo Wine SOM 7 × 7 toroidal, a variância pareada zero (std = 0) faz $d_z = 0,000$ enquanto $r_{\text{eff}} = 1,000$ (ver Seção 7.3).

como teto assintótico sob isotropia perfeita, e os valores empíricos convergem a esse limite conforme o mapa cresce.

7.2 Framework de Conformidade Executável para Bibliotecas SOM

Com base nos achados deste estudo, propõe-se um framework de conformidade executável em 4 passos, disponibilizado no repositório como `src/conformance_check.py`:

- 1) **Verificar o fator diagonal:** Para grades RECT, confirmar se a implementação divide as distâncias diagonais por $\sqrt{2}$ (ou $2\sqrt{2}$ para a média de duas diagonais, como em Costa & Netto 2007).
- 2) **Testar com mapa sintético isotrópico:** Gerar um mapa com pesos regulares onde $d_{\text{diag}}/d_{\text{ort}} = \sqrt{2}$, e verificar se $\bar{U}/d_{\text{ort}} = 1,000$.
- 3) **Reportar a variante adotada:** Documentar explicitamente se a normalização diagonal é aplicada, para garantir comparabilidade [10].
- 4) **Testar por reprodução cruzada:** Comparar resultados com implementações de referência (ex: MATLAB SOM Toolbox) em pelo menos um dataset público.

O script `src/conformance_check.py` executa o passo 2 em tempo real, identificando automaticamente se uma biblioteca apresenta o viés de inflação de 20,7%.

7.3 Impacto na Segmentação e no Agrupamento Downstream

A avaliação estatística rigorosa ($N = 30$ sementes, testes de Wilcoxon emparelhados com correção FDR de Benjamini-Hochberg a $q = 0,05$) demonstra que a omissão da normalização diagonal produz um **impacto estatisticamente significativo sobre a segmentação downstream** (ARI contra *ground truth*) na maioria das configurações testadas (20 de 36 testes, ou 55,6%).

A taxa de rejeição de H_0 varia de forma sistemática entre os datasets:

- **Synthetic Control:** 75% (9/12) das configurações rejeitaram H_0 , com tamanho de efeito moderado a elevado ($r_{\text{effect}} \in [0,40, 0,86]$ e desvio médio absoluto de ARI $|\Delta\text{ARI}|$ de até 0,074).
- **Wine:** 67% (8/12) das configurações rejeitaram H_0 , com tamanho de efeito de médio a muito elevado ($r_{\text{effect}} \in [0,39, 1,00]$).
- **Digits:** 25% (3/12) das configurações rejeitaram H_0 ($r_{\text{effect}} \in [0,48, 0,68]$).

Essa gradação revela que a detectabilidade estatística e o tamanho de efeito da normalização diagonal sobre a segmentação dependem da **sobreposição intrínseca das classes** do dataset. Em datasets com separação morfológica clara (*Synthetic Control*), a U-matrix normalizada reflete com maior precisão as fronteiras de atração entre classes, tornando as variações no relevo local diretamente determinantes para a partição de clusters. Em contrapartida, em datasets de alta dimensão e sobreposição elevada (*Digits*), a variância estocástica intrínseca dos dados atenua a sensibilidade da partição macro.

Sob a perspectiva da engenharia de software científico, embora o deslocamento médio de ARI possa parecer modesto em mapas grandes ($|\Delta\text{ARI}| \approx 0,001\text{--}0,013$ em 15×15 e 20×20), a presença de rejeições de H_0 com $p_{\text{fdr}} < 10^{-4}$ e tamanhos de efeito elevados ($r_{\text{effect}} > 0,70$, confirmados parametricamente por d_z de Cohen atingindo até 2,01) comprova que a divergência de código não é um mero ruído numérico: trata-se de um viés algorítmico real que altera a alocação de amostras em fronteiras de decisão. Ressalta-se que em 19 das 20 configurações significativas observa-se estrita concordância entre $|d_z|$ e r_{effect} ; no único caso atípico (*Wine*, SOM 7 × 7 toroidal), a diferença pareada possui

variância zero entre sementes ($\text{std} = 0$), fazendo d_z colapsar por definição matemática ($d_z = 0,000$) enquanto r_{effect} atinge o valor máximo ($r_{\text{effect}} = 1,000$, $p_{\text{fdr}} = 5,18 \times 10^{-7}$) devido à consistência absoluta do efeito.

7.4 Variação entre Bibliotecas Open-Source

Divergências similares ocorrem em outras bibliotecas: o pacote `kohonen` em R [16] também adota a média simples de normas brutas. Esse padrão de variação silenciosa entre bibliotecas é apontado por Flexer (2001) [10] como fonte de incomparabilidade entre estudos, motivando o framework de conformidade proposto na Seção 7.2.

7.5 Limitações Declaradas

Este trabalho possui as seguintes limitações metodológicas declaradas:

- 1) **Escopo Geométrico:** A análise empírica é restrita à malha retangular (RECT) 2-D. Malhas hexagonais (HEX) dispõem de simetria radial equiângula de 6 vizinhos e não apresentam essa distorção.
- 2) **Suporte a Saídas 3-D:** A extensão a U-arrays 3-D derivada na Seção 4.3 permanece teórica, uma vez que a IntraSOM 1.1.1 suporta apenas grades 2-D.
- 3) **Poder Estatístico e Tamanho de Amostra:** O estudo utilizou $N = 30$ sementes por configuração; amostras maiores poderiam detectar efeitos sutis em mapas de altíssima dimensão.
- 4) **Método de Segmentação:** A partição de clusters foi avaliada via K-Means; métodos topo-dependentes (ex: *watershed*) podem exibir sensibilidades distintas.

7.6 Trabalhos Futuros

Propõem-se as seguintes direções de pesquisa:

- **Correção da API:** Submeter *Pull Request* ao repositório oficial da IntraSOM adicionando o parâmetro opcional `build_umatrix(normalize_diagonals)`.
- **Validação Empírica 3-D:** Avaliar o fator de inflação teórico de 41,64% em U-arrays 3-D utilizando uma implementação de referência tridimensional.
- **Extensão a Mais Bibliotecas:** Aplicar o framework de conformidade executável (`src/conformance_check.py`) a outras bibliotecas SOM (MiniSom, SOMpy, MATLAB SOM Toolbox).

8 CONCLUSÃO

Este artigo apresentou uma análise empírica e teórica da U-matrix na biblioteca IntraSOM (v1.1.1), demonstrando que a omissão da normalização diagonal $1/\sqrt{2}$ (Costa & Netto, 2007) produz uma inflação empírica sistemática de 16,8%–20,5%, delimitada pelo teto teórico $(1 + \sqrt{2})/2 \approx 1,207$. A generalização teórica 3-D estabeleceu o limite assintótico de 41,64% para U-arrays tridimensionais. O estudo de larga escala—1 080 modelos SOM, $N = 30$ sementes, 3 datasets—confirma a generalidade do achado. Os testes de Wilcoxon emparelhados com correção FDR de Benjamini-Hochberg demonstram que a divergência tem significância estatística

em 55,6% das 36 configurações testadas (75% em *Synthetic Control*, 67% em *Wine*, 25% em *Digits*), com tamanhos de efeito de Rosenthal variando entre 0,39 e 1,00.

A contribuição principal é quadrupla: (i) a descoberta e quantificação rigorosa da divergência na IntraSOM v1.1.1; (ii) a derivação analítica 2-D e 3-D dos limites teóricos de inflação; (iii) a proposição de um framework de conformidade executável (`src/conformance_check.py`); e (iv) a proposta concreta de correção da API.

AGRADECIMENTOS

O autor expressa seu agradecimento ao Prof. Dr. José Alfredo Ferreira Costa (UFRN) pela supervisão acadêmica no âmbito de projeto de iniciação científica, fornecendo orientação conceitual sobre a estrutura da U-matrix sem envolvimento na execução experimental ou redação.

REFERÊNCIAS

- [1] T. Kohonen, "Self-organized formation of topologically correct feature maps," *Biological Cybernetics*, vol. 43, no. 1, pp. 59–69, 1982.
- [2] —, *Self-Organizing Maps*, 3rd ed., ser. Springer Series in Information Sciences. Berlin, Heidelberg: Springer-Verlag, 2001, vol. 30.
- [3] —, "Essentials of the self-organizing map," *Neural Networks*, vol. 37, pp. 52–65, 2013.
- [4] J. Vesanto and E. Alhoniemi, "Clustering of the self-organizing map," *IEEE Transactions on Neural Networks*, vol. 11, no. 3, pp. 586–600, 2000.
- [5] R. C. T. de Gouvêa, R. d. S. Gioria, G. R. Marques, and C. d. C. Carneiro, "IntraSOM: A comprehensive Python library for Self-Organizing Maps with hexagonal toroidal maps training and missing data handling," *Software Impacts*, vol. 17, p. 100570, 2023.
- [6] R. D. Peng, "Reproducible research in computational science," *Science*, vol. 334, no. 6060, pp. 1226–1227, 2011.
- [7] V. Stodden and S. Miguez, "Best practices for computational science: Software infrastructure and environments for reproducible and extensible research," *Journal of Open Research Software*, vol. 2, no. 1, p. e21, 2014.
- [8] D. Sculley, G. Holt, D. Golovin, E. Davydov, T. Phillips, D. Ebner, V. Chaudhary, M. Young, J.-F. Crespo, and D. Dennison, "Hidden technical debt in machine learning systems," *Advances in Neural Information Processing Systems*, vol. 28, pp. 2503–2511, 2015.
- [9] G. K. Sandve, A. Nekrutenko, J. Taylor, and E. Hovig, "Ten simple rules for reproducible computational research," *PLOS Computational Biology*, vol. 9, no. 10, p. e1003285, 2013.
- [10] A. Flexer, "On the use of self-organizing maps for clustering and visualization," *Intelligent Data Analysis*, vol. 5, no. 5, pp. 373–384, 2001.
- [11] A. Ultsch and H. P. Siemon, "Kohonen's self organizing feature maps for exploratory data analysis," in *Proceedings of International Neural Network Conference (INNC'90)*, vol. 1. Dordrecht, Netherlands: Kluwer Academic Press, 1990, pp. 305–308.
- [12] A. Ultsch, "Self-organizing neural networks for visualization and classification," in *Information and Classification: Concepts, Methods and Applications*, O. Opitz, B. Lausen, and R. Klar, Eds. Berlin, Heidelberg: Springer-Verlag, 1993, pp. 307–313.
- [13] J. A. F. Costa and M. L. d. A. Netto, "Segmentação de mapas auto-organizáveis com espaço de saída 3-d," *Revista Controle & Automação*, vol. 18, no. 2, pp. 150–162, 2007.
- [14] J. Venna and S. Kaski, "Visualizing gene expression data using self-organizing maps," *Neural Networks*, vol. 20, no. 2, pp. 226–236, 2007.
- [15] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.
- [16] R. Wehrens and L. M. C. Buydens, "Self- and super-organizing maps in R: The `kohonen` package," *Journal of Statistical Software*, vol. 21, no. 5, pp. 1–19, 2007.

- [17] R. J. Alcock and Y. Manolopoulos, "Time-series similarity queries employing a feature-based approach," in *Proceedings of the 7th Hellenic Conference on Informatics (PCI 1999)*, Ioannina, Greece, 1999, pp. 13–24.
- [18] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*, ser. Monographs on Statistics and Applied Probability. Boca Raton, FL: CRC Press, 1994, vol. 57.
- [19] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.