

Efeito da Normalização Diagonal na U-Matrix de SOMs Retangulares: Uma Reanálise Empírica da Biblioteca IntraSOM 1.1.1 à Luz de Costa & Netto (2007)

Cauã Vitor

Resumo—A Matriz de Distâncias Unificada (*U-matrix*) é a principal ferramenta de visualização e segmentação de Mapas Auto-Organizáveis (SOM) com grade retangular. A formulação clássica de Costa & Netto (2007), que generaliza Ultsch (1993), exige a divisão das distâncias diagonais pelo fator de escala geométrica $\sqrt{2}$ para garantir a isotropia do gradiente espacial no espaço de pesos. Este trabalho demonstra, mediante análise do código-fonte e experimento quantitativo sobre 12 modelos RECT treinados no dataset *Synthetic Control* (600 amostras, 6 classes), que a biblioteca IntraSOM 1.1.1 não aplica esse fator: a média é calculada sobre normas euclidianas brutas das 8 direções sem ponderação espacial. A divergência resultante é sistemática e mensurável: a implementação atual inflaciona os valores da U-matrix em 17,3% a 20,4% em relação à formulação clássica (escala média de 1,19–1,20), com correlação espacial de Pearson $r \geq 0,985$ entre as duas versões. O Adjusted Rand Index entre as segmentações resultantes varia de 0,42 a 0,96, indicando que em mapas menores a escolha de implementação afeta sensivelmente a partição de *clusters*. Este resultado motiva a inclusão de um parâmetro opcional `normalize_diagonals` na biblioteca, e documenta um padrão recorrente de divergência entre fórmulas publicadas e implementações de bibliotecas de SOM.

Index Terms—Mapas Auto-Organizáveis, U-Matrix, Normalização Diagonal, IntraSOM, Reprodutibilidade, Engenharia de Software Científica.

1 INTRODUÇÃO

OS Mapas Auto-Organizáveis de Kohonen (*Self-Organizing Maps* — SOM) [1], [2] são amplamente utilizados para a projecção e visualização de dados multidimensionais em grades de baixa dimensão, preservando relações de vizinhança topológica. Uma das representações mais influentes para a interpretação de mapas treinados é a Matriz de Distâncias Unificada (*U-matrix*), introduzida por Ultsch (1993) [3] e formalizada matematicamente por Costa

& Netto (2007) [4]. A U-matrix converte distâncias no espaço de pesos em relevos tridimensionais onde vales identificam regiões homogêneas (*clusters*) e cristas marcam fronteiras entre classes.

A proliferação de bibliotecas de código aberto para SOM — como a *kohonen* em R [5], a *MiniSom* em Python [6], e a *IntraSOM* [7] — democratizou o uso do algoritmo, mas introduziu uma heterogeneidade de escolhas de implementação que nem sempre é documentada ou verificada em relação à literatura de referência [8], [9]. A ausência de testes de conformidade (*conformance testing*) entre a fórmula publicada e o código executado representa uma ameaça silenciosa à reprodutibilidade em aprendizado de máquina [10].

Este trabalho documenta e quantifica um caso concreto: a implementação da U-matrix reduzida para grades retangulares na biblioteca IntraSOM 1.1.1 diverge da formulação clássica de Ultsch [3] e Costa & Netto [4] na normalização das distâncias diagonais. A omissão do fator $1/\sqrt{2}$ nas quatro direções diagonais produz uma inflação sistemática dos valores da U-matrix, com consequências mensuráveis sobre a segmentação.

As contribuições deste trabalho são:

- 1) Demonstração analítica da divergência entre as duas formulações, com derivação do fator de inflação esperado.
- 2) Quantificação empírica sobre 12 modelos RECT treinados (planar e toroidal, 5×5 a 20×20) com métricas de correlação espacial, diferença relativa e impacto na segmentação.
- 3) Proposta de extensão da API da biblioteca com parâmetro `normalize_diagonals`.

O restante deste artigo está estruturado da seguinte forma: a Seção 2 revisa a formulação teórica; a Seção 3 analisa a divergência; a Seção 4 descreve o protocolo experimental; a Seção 5 apresenta os resultados; e a Seção 6 discute implicações e trabalhos futuros.

C. Vitor é graduando em Engenharia Elétrica e pesquisador na Universidade Federal do Rio Grande do Norte (UFRN), Natal, RN, Brasil. E-mail: caua.vitor@ufrn.br.

Supervisão Acadêmica: Prof. Dr. José Alfredo Ferreira Costa (Departamento de Engenharia Elétrica, UFRN).

2 FUNDAMENTAÇÃO TEÓRICA

2.1 O Algoritmo SOM e o Espaço de Pesos

O SOM de Kohonen [1] consiste em $M = R \times C$ neurônios dispostos em grade retangular de R linhas e C colunas. A cada neurônio (r, c) está associado um vetor de pesos $\mathbf{w}_{r,c} \in \mathbb{R}^n$. Dados de entrada $\mathbf{x} \in \mathbb{R}^n$ são mapeados para o Neurônio de Melhor Ajuste (*Best Matching Unit* — BMU):

$$(r^*, c^*) = \arg \min_{r,c} \{\|\mathbf{x} - \mathbf{w}_{r,c}\|\}. \quad (1)$$

Os vetores de pesos são atualizados iterativamente segundo a regra de Kohonen [11], com função de vizinhança gaussiana de raio $\sigma(t)$ decrescente ao longo das épocas.

2.2 Formulação Clássica da U-Matrix

A U-matrix codifica a estrutura de densidade do espaço de pesos [3]. Para uma grade retangular, Costa & Netto (2007) [4] definem as distâncias inter-neurônios nas direções ortogonais e diagonais:

$$dx(r, c) = \|\mathbf{w}_{r,c} - \mathbf{w}_{r,c+1}\|, \quad (2)$$

$$dy(r, c) = \|\mathbf{w}_{r,c} - \mathbf{w}_{r+1,c}\|, \quad (3)$$

$$dxy(r, c) = \frac{\|\mathbf{w}_{r,c} - \mathbf{w}_{r+1,c+1}\| + \|\mathbf{w}_{r,c+1} - \mathbf{w}_{r+1,c}\|}{2\sqrt{2}}. \quad (4)$$

O elemento crítico da Eq. (4) é o divisor $2\sqrt{2}$. Em uma grade retangular com passo unitário, a distância geométrica entre neurônios diagonalmente adjacentes é $\sqrt{1^2 + 1^2} = \sqrt{2}$. Dividir por $\sqrt{2}$ é, portanto, a normalização do gradiente espacial $\Delta \mathbf{w} / \Delta s$ pelo comprimento do passo $\Delta s = \sqrt{2}$. Sem essa normalização, os canais diagonais recebem implicitamente um peso $\sqrt{2} \approx 1,414$ vezes maior do que os canais ortogonais na média final, distorcendo a isotropia da U-matrix.

A U-matrix reduzida por neurônio é a média das distâncias normalizadas de todos os vizinhos válidos [6], [12]:

$$U(r, c) = \frac{1}{|\mathcal{N}(r, c)|} \sum_{k \in \mathcal{N}(r, c)} d_k(r, c) / s_k, \quad (5)$$

em que $s_k = 1$ para vizinhos ortogonais e $s_k = \sqrt{2}$ para vizinhos diagonais, e $\mathcal{N}(r, c)$ é o conjunto de vizinhos válidos de (r, c) .

3 ANÁLISE DA DIVERGÊNCIA NA BIBLIOTECA INTRASOM 1.1.1

3.1 Implementação Observada

A inspeção do método `build_umatrix` em `intrasom/intrasom.py` (linhas 135–205, versão 1.1.1) revela que, para a grade retangular (`lattice == "rect"`), todos os oito vizinhos recebem o mesmo tratamento — norma euclidiana bruta dos pesos sem o fator $1/\sqrt{2}$ nas direções diagonais:

```
offsets = np.array([
    [1, 0], [1, 1], [0, 1], [-1, 1],
    [-1, 0], [-1, -1], [0, -1], [1, -1]
], dtype=int)
...
for k in range(8):
    um[:, :, k] = np.linalg.norm(
```

```
W - W_neighbor, axis=2)
umat = np.nanmean(umat, axis=2)
```

A implementação *correta* (Eq. 5) requer a divisão por $\sqrt{2}$ nos quatro canais diagonais ($k \in \{1, 3, 5, 7\}$) antes de calcular `np.nanmean`.

3.2 Derivação do Fator de Inflação Esperado

Considere um mapa com pesos perfeitamente regulares, onde as distâncias ortogonais $d_{\perp}$ e diagonais $d_{\diag}$ satisfazem $d_{\diag} = \sqrt{2} d_{\perp}$ (gradiente isotrópico). Então:

$$U_{\text{IntraSOM}} = \frac{4d_{\perp} + 4d_{\diag}}{8} = \frac{4d_{\perp}(1 + \sqrt{2})}{8},$$

$$U_{\text{class.}} = \frac{4d_{\perp} + 4d_{\diag}/\sqrt{2}}{8} = \frac{4d_{\perp}(1 + 1)}{8} = d_{\perp},$$

$$\text{Razão} = \frac{U_{\text{IntraSOM}}}{U_{\text{class.}}} = \frac{1 + \sqrt{2}}{2} \approx 1,207.$$

O fator teórico de inflação sob a hipótese isotrópica é portanto $\approx 1,207$ (ou 20,7% de inflação relativa).

4 METODOLOGIA EXPERIMENTAL

4.1 Dataset e Modelos

O experimento utiliza o dataset *Synthetic Control* [13]: 600 séries temporais de 60 passos divididas em 6 classes morfológicas ($n = 100$ por classe). Foram avaliados 12 modelos RECT previamente treinados com a biblioteca IntraSOM 1.1.1 (Batch SOM, inicialização PCA, 500 épocas totais: 150 rough + 350 finetune), cruzando 2 topologias (planar e toroidal) com 6 dimensões de grade (5×5 , 7×7 , 10×10 , 12×12 , 15×15 , 20×20). Seed única fixada em todos os treinamentos (`numpy.random.seed(42)`).

Os modelos HEX não são incluídos neste experimento pois a divergência de normalização é específica da geometria retangular — a grade hexagonal não possui conexões diagonais no mesmo sentido geométrico.

4.2 Protocolo de Comparação

Para cada modelo treinado (sem retreinamento, usando os mesmos pesos), computam-se duas U-matrizes reduzidas:

- 1) U_A (**IntraSOM 1.1.1**): via `som.build_umatrix(expanded=True)` seguido de `np.nanmean(axis=2)` — comportamento padrão da biblioteca.
- 2) U_B (**Clássica**): reimplementação da Eq. (5) com fator $s_k = \sqrt{2}$ nos canais diagonais, usando os mesmos pesos do codebook.

4.3 Métricas de Divergência

As seguintes métricas de divergência são calculadas por modelo:

- **Correlação de Pearson r** : mede a preservação da topologia relativa (padrão espacial).
- **Diferença Relativa Média**: $|\Delta U| / \bar{U}_B \times 100$ (em %).
- **Razão de Escala**: $\bar{U}_A / \bar{U}_B$.
- **ARI de Segmentação**: Adjusted Rand Index entre as partições de $k = 6$ clusters obtidas por K-Means sobre U_A e U_B separadamente.

5 RESULTADOS

5.1 Visualização das Duas U-Matrizes

A Fig. 1 exibe as U-matrizes U_A e U_B para o modelo SOM 10×10 RECT toroidal. O padrão espacial (topologia de vales e cristas) é visualmente preservado ($r = 0,9992$), mas U_A exibe valores sistematicamente mais altos: a razão de escala é 1,204, e a diferença relativa média é 20,4%.




Figura 1. Comparação das U-matrizes U_A (IntraSOM 1.1.1) e U_B (Costa & Netto 2007) para o modelo SOM 10×10 RECT toroidal. Painel (a): U_A sem normalização diagonal. Painel (b): U_B com fator $1/\sqrt{2}$ nas direções diagonais. Painel (c): diferença absoluta $|U_A - U_B|$, evidenciando o padrão sistemático da inflação. Pearson $r = 0,9992$; inflação relativa média = 20,4%.

5.2 Distribuição da Divergência

A Fig. 2 mostra que a divergência relativa por neurônio tem distribuição aproximadamente normal centrada em torno de 20,4% para o modelo RECT toroidal 10×10 , confirmando a natureza sistemática (não aleatória) da inflação. O painel direito exibe a divergência média por modelo: RECT toroidais convergem para $\approx 20,3\%$ e RECT planares para $\approx 18,5\%$ – $19,9\%$, valores próximos ao limite teórico derivado na Seção 3.2 (20,7%).




Figura 2. (a) Distribuição da divergência relativa por neurônio para o modelo SOM 10×10 RECT toroidal ($n = 100$ neurônios). (b) Divergência relativa média (%) por modelo e topologia, mostrando que a inflação é sistemática e escala com a dimensão da grade.

5.3 Sistematicidade em Função do Tamanho da Grade

A Tabela 1 resume as métricas para os 12 modelos. A Fig. 3 confirma que a razão de escala $\bar{U}_A/\bar{U}_B$ converge rapidamente para 1,20 com o aumento da grade, consistente com o limite teórico de 1,207.

5.4 Impacto na Segmentação da U-Matrix

A Fig. 4 mostra o ARI entre as partições de $k = 6$ clusters geradas por K-Means sobre U_A e U_B separadamente. Para os mapas 5×5 , o ARI cai para 0,42–0,48, indicando que a escolha de implementação afeta substancialmente a partição.

Tabela 1
Métricas de Divergência entre U_A (IntraSOM 1.1.1) e U_B (Costa & Netto 2007) para os 12 Modelos RECT

Modelo	r	Dif. Rel. (%)	Escala $\bar{U}_A/\bar{U}_B$	ARI Seg.
5×5 Planar	0.9855	17.26	1.173	0.477
5×5 Toróide	0.9893	20.07	1.201	0.417
7×7 Planar	0.9973	18.03	1.180	0.963
7×7 Toróide	0.9983	20.26	1.203	0.935
10×10 Planar	0.9975	18.91	1.189	0.556
10×10 Toróide	0.9992	20.42	1.204	0.816
12×12 Planar	0.9978	19.39	1.194	0.886
12×12 Toróide	0.9994	20.33	1.203	0.952
15×15 Planar	0.9984	19.72	1.197	0.854
15×15 Toróide	0.9993	20.22	1.202	0.805
20×20 Planar	0.9985	19.83	1.198	0.838
20×20 Toróide	0.9995	20.30	1.203	0.887




Figura 3. Sistematicidade da divergência em função do tamanho da grade N . (a) Diferença relativa média (%), que converge para $\approx 20,3\%$ (toroidal) e $\approx 19,8\%$ (planar). (b) Razão de escala $\bar{U}_A/\bar{U}_B$, que se aproxima do limite teórico 1,207 com o aumento de N .

Para mapas maiores ($\geq 12 \times 12$), o ARI geralmente supera 0,85, sugerindo maior estabilidade topológica. Essa heterogeneidade evidencia que o impacto prático depende da complexidade da estrutura de *clusters* no mapa.




Figura 4. Adjusted Rand Index (ARI) entre as segmentações de U_A e U_B para $k = 6$ clusters (K-Means). Valores abaixo de 0,8 indicam que a escolha de implementação afeta sensivelmente a partição de *clusters* — com efeito mais pronunciado em mapas menores (5×5).

6 DISCUSSÃO

6.1 Significância Prática da Divergência

Os resultados confirmam que a IntraSOM 1.1.1 implementa uma variação da U-matrix que difere da formulação de Ultsch [3] e Costa & Netto [4] na normalização das distâncias

diagonais. A inflação systemática de $\approx 20\%$ não invalida a ferramenta para fins de visualização relativa (o padrão espacial é preservado com $r \geq 0,985$), mas tem consequências operacionais importantes:

- 1) **Limiar de segmentação:** algoritmos de watershed ou K-Means sobre a U-matrix com limiar absoluto produzem partições diferentes nas duas versões, especialmente em mapas pequenos.
- 2) **Comparabilidade entre implementações:** pesquisadores que comparam U-matrizes de ferramentas distintas precisam verificar qual normalização foi utilizada.
- 3) **Reprodutibilidade de resultados:** relatórios que publicam limiares ou números de *clusters* derivados da U-matrix sem especificar a implementação são potencialmente não reprodutíveis [8], [14].

6.2 Comparação com o Limite Teórico

A razão de escala observada (1,17–1,20) é consistente com o limite teórico de 1,207 derivado na Seção 3.2, mas ligeiramente inferior, o que é esperado: em um mapa treinado real os pesos não são perfeitamente isotrópicos, e a relação $d_{\parallel} = \sqrt{2}d_{\perp}$ é uma aproximação. Os mapas planares apresentam valores ligeiramente menores que os toroidais ($\approx 18,7\%$ vs. $\approx 20,3\%$), provavelmente porque as bordas planares produzem neurônios de borda com menos vizinhos diagonais válidos, reduzindo o peso relativo dos canais afetados.

6.3 Padrões de Divergência em Bibliotecas de SOM

Esta divergência não é exclusiva da IntraSOM. A implementação mais usada de U-matrix (biblioteca *kohonen* em R, [5]) também computa a média simples sobre todas as distâncias euclidianas brutas dos vizinhos, sem o fator $1/\sqrt{2}$ nas diagonais. Flexer (2001) [12] nota que a implementação precisa da U-matrix varia entre ferramentas, e que resultados de agrupamento podem depender dessas escolhas. O presente trabalho fornece a primeira quantificação empírica sistemática dessa divergência para modelos treinados no contexto da biblioteca IntraSOM.

6.4 Notas de Engenharia de Software

Durante o desenvolvimento do sistema (*intrasom-kohonen*), identificaram-se e corrigiram-se seis anomalias adicionais de software que afetavam a paridade metodológica entre as 4 variantes do SOM (HEX/RECT $\times$ planar/toroidal): (i) motor duplo MiniSom/IntraSOM; (ii) distância toroidal RECT calculada com métrica incorreta; (iii) contagem de arestas da U-matrix expandida usando 6 vizinhos HEX para grades RECT; (iv) *monkey-patch* de distância Manhattan obsoleto; (v) dimensões efetivas divergentes entre HEX e RECT para tamanhos ímpares; e (vi) *QE* travado em zero após desserialização de modelos. Esses achados estão documentados em detalhe no relatório técnico `ENGINEERING_AUDIT.md` do repositório [9], [10].

6.5 Trabalhos Futuros

- 1) Submeter *Pull Request* à biblioteca IntraSOM propondo `build_umatrix(normalize_diagonals=True)` como

comportamento padrão, com compatibilidade retroativa por *flag*.

- 2) Estender a análise para grades hexagonais, que também podem apresentar divergências em implementações de vizinhança de *offset* [13].
- 3) Quantificar o impacto sobre métricas de segmentação (ARI, NMI) usando mapeamento direto dos dados sobre a U-matrix, ao invés de K-Means sobre valores da matrix.
- 4) Expandir a visualização do dashboard interativo para suportar a estrutura U-array 3-D proposta por Costa & Netto (2007) [4], que generaliza a U-matrix para grades de saída tridimensionais.

7 CONCLUSÃO

Este trabalho demonstrou, por análise do código-fonte e experimento quantitativo sobre 12 modelos RECT, que a biblioteca IntraSOM 1.1.1 implementa a U-matrix reduzida para grades retangulares sem o fator de normalização diagonal $1/\sqrt{2}$ exigido pela formulação clássica de Ultsch (1993) e Costa & Netto (2007). A divergência é sistemática ($\approx 17\%$ – 20% de inflação relativa), corroborada pelo limite teórico de $20,7\%$ derivado analiticamente, e afeta sensivelmente a segmentação em mapas pequenos ($ARI < 0,5$ para 5×5).

Os resultados sublinham a importância da verificação formal de conformidade entre fórmulas publicadas e implementações de bibliotecas em pesquisa reprodutível com aprendizado de máquina. A proposta de extensão da API com `normalize_diagonals` permite que usuários escolham explicitamente a formulação desejada, tornando transparente uma escolha que hoje é implícita.

AGRADECIMENTOS

O autor expressa seu sincero agradecimento ao Prof. Dr. José Alfredo Ferreira Costa (UFRN) pela orientação acadêmica e pelas contribuições teóricas sobre a estrutura da U-matrix e a sua extensão tridimensional (U-array).

REFERÊNCIAS

- [1] T. Kohonen, "Self-organized formation of topologically correct feature maps," *Biological Cybernetics*, vol. 43, no. 1, pp. 59–69, 1982.
- [2] —, *Self-Organizing Maps*, 3rd ed., ser. Springer Series in Information Sciences. Berlin, Heidelberg: Springer-Verlag, 2001, vol. 30.
- [3] A. Ultsch, "Self-organizing neural networks for visualization and classification," in *Information and Classification: Concepts, Methods and Applications*, O. Opitz, B. Lausen, and R. Klar, Eds. Berlin, Heidelberg: Springer-Verlag, 1993, pp. 307–313.
- [4] J. A. F. Costa and M. L. d. A. Netto, "Segmentação de mapas auto-organizáveis com espaço de saída 3-d," *Revista Controle & Automação*, vol. 18, no. 2, pp. 150–162, 2007.
- [5] R. Wehrens and L. M. C. Buydens, "Self- and super-organizing maps in R: The *kohonen* package," *Journal of Statistical Software*, vol. 21, no. 5, pp. 1–19, 2007.
- [6] J. Vesanto and E. Alhoniemi, "Clustering of the self-organizing map," *IEEE Transactions on Neural Networks*, vol. 11, no. 3, pp. 586–600, 2000.
- [7] Universidade de São Paulo, "Intrasom: Interactive self-organizing maps library in python," PyPI Package Version 1.1.1, 2026, acessado em julho de 2026. [Online]. Available: <https://pypi.org/project/intrasom/>
- [8] R. D. Peng, "Reproducible research in computational science," *Science*, vol. 334, no. 6060, pp. 1226–1227, 2011.

- [9] G. K. Sandve, A. Nekrutenko, J. Taylor, and E. Hovig, "Ten simple rules for reproducible computational research," *PLOS Computational Biology*, vol. 9, no. 10, p. e1003285, 2013.
- [10] D. Sculley, G. Holt, D. Golovin, E. Davydov, T. Phillips, D. Ebner, V. Chaudhary, M. Young, J.-F. Crespo, and D. Dennison, "Hidden technical debt in machine learning systems," *Advances in Neural Information Processing Systems*, vol. 28, pp. 2503–2511, 2015.
- [11] T. Kohonen, "Essentials of the self-organizing map," *Neural Networks*, vol. 37, pp. 52–65, 2013.
- [12] A. Flexer, "On the use of self-organizing maps for clustering and visualization," *Intelligent Data Analysis*, vol. 5, no. 5, pp. 373–384, 2001.
- [13] S. Kaski and K. Lagus, "Comparing self-organizing maps," in *Proceedings of the International Conference on Artificial Neural Networks (ICANN'96)*, ser. Lecture Notes in Computer Science, vol. 1112. Berlin, Heidelberg: Springer-Verlag, 1996, pp. 809–814.
- [14] V. Stodden and S. Miguez, "Best practices for computational science: Software infrastructure and environments for reproducible and extensible research," *Journal of Open Research Software*, vol. 2, no. 1, p. e21, 2014.