

[Nota Técnica] Efeito da Normalização Diagonal na U-Matrix de SOMs Retangulares: Uma Reanálise Empírica da Biblioteca IntraSOM à Luz de Costa & Netto (2007)

Cauã Vitor

Resumo—A Matriz de Distâncias Unificada (*U-matrix*) é a principal ferramenta de visualização e segmentação de Mapas Auto-Organizáveis (SOM) com grade retangular. A formulação clássica de Costa & Netto (2007), que generaliza Ultsch (1993), exige a divisão das distâncias diagonais pelo fator de escala geométrica $\sqrt{2}$ para garantir a isotropia do gradiente espacial no espaço de pesos. Este trabalho demonstra, mediante análise do código-fonte e experimentos com repetição estatística sob inicialização aleatória estocástica (5 sementes aleatórias, totalizando 60 treinamentos) no dataset *Synthetic Control* (Alcock & Manolopoulos, 1999; 600 amostras, 6 classes), que a biblioteca open-source IntraSOM (Gouvêa et al., 2023) não aplica esse fator: a média é calculada sobre normas euclidianas brutas das 8 direções sem ponderação espacial. A divergência resultante é sistemática e mensurável: a implementação atual inflaciona os valores da U-matrix em $16,8\% \pm 0,2\%$ a $20,5\% \pm 0,0\%$ em relação à formulação clássica (razão de escala média de 1,168 a 1,205), com alta correlação espacial de Pearson ($r \geq 0,989$) entre as duas versões. A derivação teórica estabelece $(1 + \sqrt{2})/2 \approx 1,207$ como limite assintótico superior sob isotropia perfeita. O Adjusted Rand Index (ARI) entre as segmentações das duas U-matrizes varia de $0,54 \pm 0,18$ a $0,96 \pm 0,00$, enquanto o ARI contra os rótulos reais do dataset permanece estável ($0,09$ – $0,26$). Este resultado motiva a inclusão do parâmetro opcional `normalize_diagonals` na biblioteca e documenta a importância da verificação de conformidade entre equações publicadas e código.

Index Terms—Mapas Auto-Organizáveis, U-Matrix, Normalização Diagonal, IntraSOM, Reprodutibilidade, Engenharia de Software Científica.

1 INTRODUÇÃO

OS Mapas Auto-Organizáveis de Kohonen (*Self-Organizing Maps* — SOM) [1], [2] são amplamente utilizados para projeção e visualização de dados multidimensionais em grades de baixa dimensão. A biblioteca IntraSOM [3], publicada recentemente no periódico *Software Impacts*, destaca-se como um pacote open-source em Python

desenvolvido para suprir demandas de treinamento em malhas hexagonais e toroidais com suporte a dados ausentes, sendo adotada em pesquisas aplicadas, centros como o InTRA-USP e projetos acadêmicos. Com o aumento da adoção de bibliotecas de aprendizado de máquina em sistemas numéricos, a verificação formal de fidelidade algorítmica torna-se essencial para evitar que divergências sutis de código afetem a reprodutibilidade científica [4], [5].

Uma das representações mais influentes para a interpretação de mapas treinados é a Matriz de Distâncias Unificada (*U-matrix*), introduzida por Ultsch & Siemon (1990) [6], detalhada por Ultsch (1993) [7] e formalizada matematicamente por Costa & Netto (2007) [8]. A U-matrix converte distâncias no espaço de pesos em relevos tridimensionais onde vales identificam regiões homogêneas (*clusters*) e cristas marcam fronteiras entre classes.

Contudo, a proliferação de pacotes open-source — como o pacote *kohonen* em R [9] e a IntraSOM [3] — introduziu variações de implementação que nem sempre são documentadas em relação à literatura de referência [10]. A ausência de testes de conformidade (*conformance testing*) entre a fórmula publicada e a rotina numérica executada representa uma fonte de dívida técnica em sistemas de IA [11], [12].

Este trabalho documenta e quantifica uma divergência concreta: a implementação da U-matrix reduzida para grades retangulares na biblioteca IntraSOM (versão 1.1.1) [3] não aplica o fator de normalização espacial $1/\sqrt{2}$ nas conexões diagonais previsto por Costa & Netto (2007) [8]. Através de repetição estatística sob inicialização aleatória com 5 sementes estocásticas em 12 modelos RECT, demonstra-se que a omissão desse fator produz uma inflação sistemática dos valores da U-matrix, com impacto mensurável sobre a segmentação.

As contribuições desta Nota Técnica são:

- 1) **Derivação Analítica:** Demonstração do fator de inflação teórico $(1 + \sqrt{2})/2 \approx 1,207$ como limite assintótico superior sob isotropia.
- 2) **Experimento Estocástico Multissemente:** Avaliação quantitativa com inicialização aleatória em 5 seeds ($N = 60$ treinamentos) reportando média e desvio

C. Vitor é graduando em Engenharia Elétrica e pesquisador na Universidade Federal do Rio Grande do Norte (UFRN), Natal, RN, Brasil. E-mail: caua.vitor@ufrn.br.

Supervisão Acadêmica: Prof. Dr. José Alfredo Ferreira Costa (Departamento de Engenharia Elétrica, UFRN). O orientador forneceu supervisão acadêmica e discussão conceitual sobre a U-matrix, sem envolvimento na execução dos experimentos numéricos ou na redação deste manuscrito.

padrão real para correlação de Pearson, diferença relativa, razão de escala e ARI de segmentação.

- 3) **Avaliação Downstream:** Análise do impacto na qualidade real de agrupamento contra rótulos de referência (*ground truth*).
- 4) **Proposta de Correção:** Sugestão de extensão da API da biblioteca via parâmetro `normalize_diagonals`.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 O Algoritmo SOM e o Espaço de Pesos

O SOM de Kohonen [1] consiste em $M = R \times C$ neurônios dispostos em grade retangular de R linhas e C colunas. A cada neurônio (r, c) está associado um vetor de pesos $\mathbf{w}_{r,c} \in \mathbb{R}^n$. Dados de entrada $\mathbf{x} \in \mathbb{R}^n$ são mapeados para o Neurônio de Melhor Ajuste (*Best Matching Unit* — BMU):

$$(r^*, c^*) = \arg \min_{r,c} \{\|\mathbf{x} - \mathbf{w}_{r,c}\|\}. \quad (1)$$

Os vetores de pesos são atualizados iterativamente segundo a regra de Kohonen [13], com função de vizinhança gaussiana de raio $\sigma(t)$ decrescente ao longo das épocas.

2.2 Formulação Clássica da U-Matrix

A U-matrix codifica a estrutura de densidade do espaço de pesos [7]. Para uma grade retangular, Costa & Netto (2007) [8] definem as distâncias inter-neurônios nas direções ortogonais e diagonais:

$$dx(r, c) = \|\mathbf{w}_{r,c} - \mathbf{w}_{r,c+1}\|, \quad (2)$$

$$dy(r, c) = \|\mathbf{w}_{r,c} - \mathbf{w}_{r+1,c}\|, \quad (3)$$

$$dxy(r, c) = \frac{\|\mathbf{w}_{r,c} - \mathbf{w}_{r+1,c+1}\| + \|\mathbf{w}_{r,c+1} - \mathbf{w}_{r+1,c}\|}{2\sqrt{2}}. \quad (4)$$

O elemento crítico da Eq. (4) é o divisor $2\sqrt{2}$. Em uma grade retangular com passo unitário, a distância geométrica entre neurônios diagonalmente adjacentes é $\sqrt{1^2 + 1^2} = \sqrt{2}$. Dividir por $\sqrt{2}$ é, portanto, a normalização do gradiente espacial $\Delta \mathbf{w} / \Delta s$ pelo comprimento do passo $\Delta s = \sqrt{2}$. Sem essa normalização, os canais diagonais recebem implicitamente um peso $\sqrt{2} \approx 1,414$ vezes maior do que os canais ortogonais na média final, distorcendo a isotropia da U-matrix.

A U-matrix reduzida por neurônio é a média das distâncias normalizadas de todos os vizinhos válidos [10], [14]:

$$U(r, c) = \frac{1}{|\mathcal{N}(r, c)|} \sum_{k \in \mathcal{N}(r, c)} d_k(r, c) / s_k, \quad (5)$$

em que $s_k = 1$ para vizinhos ortogonais e $s_k = \sqrt{2}$ para vizinhos diagonais, e $\mathcal{N}(r, c)$ é o conjunto de vizinhos válidos de (r, c) .

3 ANÁLISE DA DIVERGÊNCIA NA BIBLIOTECA INTRASOM

3.1 Implementação Observada

A inspeção do método `build_umatrix` na classe SOM da biblioteca IntraSOM (localizado na linha 2626 de `intrasom/intrasom.py`, versão 1.1.1) [3] revela que, para a grade retangular (`lattice == "rect"`), todos os oito

vizinhos recebem norma euclidiana bruta dos pesos sem o fator $1/\sqrt{2}$ nas direções diagonais:

```
offsets = np.array([
    [1,0], [1,1], [0,1], [-1,1],
    [-1,0], [-1,-1], [0,-1], [1,-1]
], dtype=int)
for k in range(8):
    um[:, :, k] = np.linalg.norm(
        W - W_neighbor, axis=2)
umat = np.nanmean(um, axis=2)
```

A implementação conforme a Eq. (5) requer a divisão por $\sqrt{2}$ nos quatro canais diagonais ($k \in \{1, 3, 5, 7\}$) antes de calcular `np.nanmean`.

3.2 Derivação do Limite Teórico de Inflação

Considere um mapa com pesos perfeitamente regulares, onde as distâncias ortogonais $d_{\perp}$ e diagonais $d_{\diag}$ satisfazem $d_{\diag} = \sqrt{2} d_{\perp}$ (gradiente isotrópico). Então:

$$U_{\text{IntraSOM}} = \frac{4d_{\perp} + 4d_{\diag}}{8} = \frac{4d_{\perp}(1 + \sqrt{2})}{8},$$

$$U_{\text{class.}} = \frac{4d_{\perp} + 4d_{\diag}/\sqrt{2}}{8} = \frac{4d_{\perp}(1 + 1)}{8} = d_{\perp},$$

$$\text{Razão} = \frac{U_{\text{IntraSOM}}}{U_{\text{class.}}} = \frac{1 + \sqrt{2}}{2} \approx 1,207.$$

O valor 1,207 (20,7% de inflação) representa o **limite assintótico superior** sob a hipótese de isotropia perfeita no espaço de pesos. Em mapas reais treinados, a divergência empírica é um valor restringido por esse teto.

4 METODOLOGIA EXPERIMENTAL

4.1 Dataset e Protocolo Multissemente

O experimento utiliza o dataset *Synthetic Control Chart Time Series* [15]: 600 séries temporais de 60 passos divididas em 6 classes morfológicas ($n = 100$ por classe).

Para garantir a variância estatística real entre execuções, foram treinadas 12 combinações do SOM retangular (2 topologias: planar e toroidal; 6 dimensões: 5×5 , 7×7 , 10×10 , 12×12 , 15×15 , 20×20) com **inicialização aleatória estocástica** (`initialization='random'`) sob **5 sementes aleatórias** ($S = \{42, 43, 44, 45, 46\}$), perfazendo um total de $N = 60$ modelos treinados (Batch SOM, 500 épocas totais). A seção 6.2 detalha a correção metodológica efetuada no controle de sementes.

4.2 Métricas de Avaliação

Para cada um dos 60 treinamentos, computam-se a U-matrix IntraSOM U_A e a U-matrix Clássica U_B . Em seguida, calculam-se as métricas e reportam-se as médias $\pm$ desvios padrão reais sobre as 5 sementes:

- **Pearson r :** correlação espacial entre U_A e U_B .
- **Diferença Relativa (%):** $|\Delta U| / \overline{U_B} \times 100$.
- **Razão de Escala:** $\overline{U_A} / \overline{U_B}$.
- **ARI de Segmentação:** ARI entre as partições de $k = 6$ clusters obtidas por K-Means sobre U_A e U_B .
- **ARI Downstream:** ARI entre a segmentação da U-matrix e os rótulos reais do dataset y : $\text{ARI}(y, \text{seg}_A)$ e $\text{ARI}(y, \text{seg}_B)$.

5 RESULTADOS

5.1 Visualização Comparativa

A Fig. 1 exibe U_A e U_B para o modelo SOM 10×10 RECT toroidal (seed 42). A topologia relativa é visualmente preservada ($r = 0,9993$), contudo U_A exibe amplitude sistematicamente superior (20,5% de inflação relativa média).




Figura 1. Comparação das U-matrizes U_A (IntraSOM) e U_B (Costa & Netto 2007) para SOM 10×10 RECT toroidal. (a) U_A sem normalização diagonal. (b) U_B com fator $1/\sqrt{2}$. (c) Diferença absoluta $|U_A - U_B|$.

5.2 Estatística Multissemente e Tabela Resumo

A Tabela 1 apresenta os resultados médios $\pm$ desvio padrão real obtidos nas 5 sementes com inicialização estocástica.

A Fig. 2 ilustra a distribuição da divergência por neurônio e a divergência média por topologia.




Figura 2. (a) Distribuição da divergência relativa por neurônio para SOM 10×10 RECT toroidal. (b) Diferença relativa média (%) por modelo e topologia (médias sobre 5 seeds estocásticas).

5.3 Sistemática e Convergência ao Teto Teórico

A Fig. 3 confirma que a razão de escala média em malhas toroidais ($1,204 \pm 0,001$) aproxima-se de forma consistente do limite assintótico teórico 1,207 (20,7%), estabilizando-se para $N \geq 10$. Mapas planares exibem valores ligeiramente inferiores ($\approx 16,8\%$ – $19,7\%$) devido à menor densidade de vizinhos diagonais nas bordas abertas.




Figura 3. Sistemática da divergência vs dimensão N . (a) Diferença relativa média (%). (b) Razão de escala média $\bar{U}_A/\bar{U}_B$.

5.4 Impacto na Segmentação e no Agrupamento Downstream

A Fig. 4 ilustra o ARI entre as partições de K-Means ($k = 6$) sobre U_A e U_B . Para mapas 5×5 , o ARI varia em $0,54 \pm 0,18$ (toroidal) e $0,76 \pm 0,17$ (planar), indicando que a escolha da matriz altera a atribuição de agrupamentos locais em grades de menor resolução.

Contudo, a avaliação *downstream* contra as 6 classes reais do dataset (colunas ARI Ground na Tabela 1) revela que o ARI global permaneceu próximo entre as duas versões ($0,24$ vs $0,18$ em 5×5 toroide; $0,14$ vs $0,14$ em 10×10 toroide). Isso indica que a omissão da normalização altera os limiares finos e valores intermediários da U-matrix, mas a capacidade global de separação macro das classes no SOM permanece limitada pela própria resolução da grade.




Figura 4. Adjusted Rand Index (ARI) entre segmentações de U_A e U_B ($k = 6$, médias sobre 5 seeds) em função do tamanho da grade.

6 DISCUSSÃO

6.1 Significância Prática e Limite Teórico

Os experimentos multissemente confirmam que a biblioteca IntraSOM (v1.1.1) [3] computa a U-matrix reduzida com norma euclidiana bruta, resultando em inflação sistemática de 16,8% a 20,5%. O valor teórico de 20,7% derivado na Seção 3.2 atua como teto assintótico sob isotropia perfeita. A alta correlação espacial ($r \geq 0,989$) demonstra que o relevo topológico relativo é preservado, mas limiares absolutos de segmentação são alterados.

6.2 Nota sobre Correção Metodológica no Controle de Sementes

Em uma revisão metodológica interna, identificou-se que a primeira versão do experimento utilizou a inicialização determinística por Análise de Componentes Principais (`initialization='pca'`). Como o treinamento Batch sem amostragem estocástica em dados completos é determinístico dada uma inicialização fixa, o protocolo anterior produzia zero variância real entre seeds (`std = 0,000`). O protocolo foi corrigido nesta versão para utilizar inicialização aleatória estocástica (`initialization='random'`), gerando desvios padrão genuínos e confirmados via teste automatizado de regressão (`tests/test_seed_variance.py`).

Tabela 1

Métricas de Divergência entre U_A (IntraSOM 1.1.1) e U_B (Costa & Netto 2007) com Repetição Estocástica (Média $\pm$ Desvio Padrão sobre 5 Seeds)

Modelo	Pearson r	Dif. Relativa (%)	Escala $\bar{U}_A/\bar{U}_B$	ARI (U_A vs U_B)	ARI Ground (U_A)	ARI Ground (U_B)
5 $\times$ 5 RECT Planar	0.9902 $\pm$ 0.0020	16.80 $\pm$ 0.18	1.168 $\pm$ 0.002	0.760 $\pm$ 0.169	0.242 $\pm$ 0.057	0.223 $\pm$ 0.074
5 $\times$ 5 RECT Toroide	0.9899 $\pm$ 0.0012	20.17 $\pm$ 0.13	1.202 $\pm$ 0.001	0.539 $\pm$ 0.184	0.237 $\pm$ 0.018	0.180 $\pm$ 0.096
7 $\times$ 7 RECT Planar	0.9973 $\pm$ 0.0000	18.03 $\pm$ 0.00	1.180 $\pm$ 0.000	0.963 $\pm$ 0.000	0.259 $\pm$ 0.000	0.256 $\pm$ 0.000
7 $\times$ 7 RECT Toroide	0.9982 $\pm$ 0.0006	20.29 $\pm$ 0.15	1.203 $\pm$ 0.002	0.882 $\pm$ 0.085	0.248 $\pm$ 0.078	0.222 $\pm$ 0.062
10 $\times$ 10 RECT Planar	0.9976 $\pm$ 0.0005	18.58 $\pm$ 0.18	1.186 $\pm$ 0.002	0.751 $\pm$ 0.057	0.191 $\pm$ 0.011	0.217 $\pm$ 0.019
10 $\times$ 10 RECT Toroide	0.9993 $\pm$ 0.0000	20.47 $\pm$ 0.03	1.205 $\pm$ 0.000	0.860 $\pm$ 0.084	0.143 $\pm$ 0.010	0.140 $\pm$ 0.015
12 $\times$ 12 RECT Planar	0.9986 $\pm$ 0.0004	19.24 $\pm$ 0.08	1.192 $\pm$ 0.001	0.817 $\pm$ 0.051	0.185 $\pm$ 0.023	0.192 $\pm$ 0.017
12 $\times$ 12 RECT Toroide	0.9994 $\pm$ 0.0001	20.35 $\pm$ 0.07	1.204 $\pm$ 0.001	0.900 $\pm$ 0.063	0.128 $\pm$ 0.014	0.137 $\pm$ 0.019
15 $\times$ 15 RECT Planar	0.9988 $\pm$ 0.0003	19.45 $\pm$ 0.14	1.194 $\pm$ 0.001	0.796 $\pm$ 0.037	0.170 $\pm$ 0.012	0.174 $\pm$ 0.007
15 $\times$ 15 RECT Toroide	0.9993 $\pm$ 0.0000	20.26 $\pm$ 0.06	1.203 $\pm$ 0.001	0.810 $\pm$ 0.032	0.124 $\pm$ 0.009	0.139 $\pm$ 0.007
20 $\times$ 20 RECT Planar	0.9990 $\pm$ 0.0003	19.73 $\pm$ 0.07	1.197 $\pm$ 0.001	0.819 $\pm$ 0.062	0.146 $\pm$ 0.012	0.154 $\pm$ 0.011
20 $\times$ 20 RECT Toroide	0.9995 $\pm$ 0.0001	20.39 $\pm$ 0.14	1.204 $\pm$ 0.001	0.897 $\pm$ 0.040	0.094 $\pm$ 0.019	0.090 $\pm$ 0.021

6.3 Variação entre Bibliotecas Open-Source

Divergências similares ocorrem em outras bibliotecas: o pacote `kohonen` em R [9] também adota a média simples de normas brutas. Conforme apontado por Flexer (2001) [10], a ausência de padronização na U-matrix pode comprometer a comparabilidade entre estudos que utilizam ferramentas distintas sem especificar a variante adotada.

6.4 Notas sobre o Relatório de Engenharia Interno

No desenvolvimento da aplicação *intrasom-kohonen*, foram corrigidos seis problemas de engenharia adicionais (motor duplo MiniSom/IntraSOM, distância toroidal RECT, arestas expandidas, monkey-patch de distância, dimensões efetivas e recálculo de QE travado em zero). Esses achados estão documentados no relatório de auditoria interna `ENGINEERING_AUDIT.md` do repositório. A citação de trabalhos gerais de reprodutibilidade [11], [12] serve apenas para contextualizar a categoria geral de dívida técnica em sistemas de IA.

6.5 Limitações do Estudo

Esta Nota Técnica possui as seguintes limitações metodológicas declaradas:

- 1) **Escopo Geométrico:** A análise é estrita à malha retangular (RECT), na qual a assimetria entre vizinhos ortogonais e diagonais exige a ponderação $1/\sqrt{2}$. Malhas hexagonais (HEX) dispõem de simetria radial equiângula de 6 vizinhos e não apresentam essa distorção ortogonal/diagonal.
- 2) **Dataset Único:** Os experimentos numéricos foram conduzidos sobre o dataset benchmark *Synthetic Control* [15].
- 3) **Método de Segmentação:** A partição de clusters foi avaliada via K-Means ($k = 6$) sobre a U-matrix; métodos topo-dependente (ex: *watershed*) podem apresentar sensibilidades distintas.

6.6 Trabalhos Futuros

Prepara-se submeter uma contribuição (*Pull Request*) ao repositório oficial da biblioteca IntraSOM adicionando o parâmetro opcional `build_umatrix(normalize_diagonals=True)`.

7 CONCLUSÃO

Esta Nota Técnica apresentou uma reanálise empírica e teórica da U-matrix na biblioteca IntraSOM (v1.1.1), demonstrando que a omissão da normalização diagonal $1/\sqrt{2}$ (Costa & Netto, 2007) produz uma inflação empírica sistemática de 16,8% a 20,5%, delimitada pelo teto teórico de 20,7%. A inclusão do parâmetro opcional `normalize_diagonals` garante a conformidade com a literatura clássica mantendo compatibilidade retroativa.

AGRADECIMENTOS

O autor expressa seu agradecimento ao Prof. Dr. José Alfredo Ferreira Costa (UFRN) pela supervisão acadêmica no âmbito de projeto de iniciação científica, fornecendo orientação conceitual sobre a estrutura da U-matrix sem envolvimento na execução experimental ou redação.

REFERÊNCIAS

- [1] T. Kohonen, "Self-organized formation of topologically correct feature maps," *Biological Cybernetics*, vol. 43, no. 1, pp. 59–69, 1982.
- [2] —, *Self-Organizing Maps*, 3rd ed., ser. Springer Series in Information Sciences. Berlin, Heidelberg: Springer-Verlag, 2001, vol. 30.
- [3] R. C. T. de Gouvêa, R. d. S. Gioria, G. R. Marques, and C. d. C. Carneiro, "IntraSOM: A comprehensive Python library for Self-Organizing Maps with hexagonal toroidal maps training and missing data handling," *Software Impacts*, vol. 17, p. 100570, 2023.
- [4] R. D. Peng, "Reproducible research in computational science," *Science*, vol. 334, no. 6060, pp. 1226–1227, 2011.
- [5] V. Stodden and S. Miguez, "Best practices for computational science: Software infrastructure and environments for reproducible and extensible research," *Journal of Open Research Software*, vol. 2, no. 1, p. e21, 2014.
- [6] A. Ultsch and H. P. Siemon, "Kohonen's self organizing feature maps for exploratory data analysis," in *Proceedings of International Neural Network Conference (INNC'90)*, vol. 1. Dordrecht, Netherlands: Kluwer Academic Press, 1990, pp. 305–308.
- [7] A. Ultsch, "Self-organizing neural networks for visualization and classification," in *Information and Classification: Concepts, Methods and Applications*, O. Opitz, B. Lausen, and R. Klar, Eds. Berlin, Heidelberg: Springer-Verlag, 1993, pp. 307–313.
- [8] J. A. F. Costa and M. L. d. A. Netto, "Segmentação de mapas auto-organizáveis com espaço de saída 3-d," *Revista Controle & Automação*, vol. 18, no. 2, pp. 150–162, 2007.
- [9] R. Wehrens and L. M. C. Buydens, "Self- and super-organizing maps in R: The *kohonen* package," *Journal of Statistical Software*, vol. 21, no. 5, pp. 1–19, 2007.
- [10] A. Flexer, "On the use of self-organizing maps for clustering and visualization," *Intelligent Data Analysis*, vol. 5, no. 5, pp. 373–384, 2001.

- [11] D. Sculley, G. Holt, D. Golovin, E. Davydov, T. Phillips, D. Ebner, V. Chaudhary, M. Young, J.-F. Crespo, and D. Dennison, "Hidden technical debt in machine learning systems," *Advances in Neural Information Processing Systems*, vol. 28, pp. 2503–2511, 2015.
- [12] G. K. Sandve, A. Nekrutenko, J. Taylor, and E. Hovig, "Ten simple rules for reproducible computational research," *PLOS Computational Biology*, vol. 9, no. 10, p. e1003285, 2013.
- [13] T. Kohonen, "Essentials of the self-organizing map," *Neural Networks*, vol. 37, pp. 52–65, 2013.
- [14] J. Vesanto and E. Alhoniemi, "Clustering of the self-organizing map," *IEEE Transactions on Neural Networks*, vol. 11, no. 3, pp. 586–600, 2000.
- [15] R. J. Alcock and Y. Manolopoulos, "Time-series similarity queries employing a feature-based approach," in *Proceedings of the 7th Hellenic Conference on Informatics (PCI 1999)*, Ioannina, Greece, 1999, pp. 13–24.